

Actividad 8: Series de tiempo

Daniela Jiménez Téllez

2024-11-12

Problema

Para los datos de las ventas de televisores analiza la serie de tiempo más apropiada:

Importación de datos

```
ventas_data <- data.frame(  
  Año = c(1, 1, 1, 1, 2, 2, 2, 2, 3, 3, 3, 3, 4, 4, 4, 4),  
  Trimestre = c(1, 2, 3, 4, 1, 2, 3, 4, 1, 2, 3, 4, 1, 2, 3, 4),  
  Ventas = c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3, 5.9, 8.0, 8.4))  
  
ventas_data$Tiempo <- 1:nrow(ventas_data)
```

Instrucciones

1. Realiza el análisis de tendencia y estacionalidad:

- Identifica si es una serie estacionaria
- Grafica la serie para verificar su tendencia y estacionalidad
- Analiza su gráfico de autocorrelación
- Identifica si el modelo puede ser sumativo o multiplicativo (puedes probar con ambos para ver con cuál es mejor el modelo)

```
ventas_ts <- ts(ventas_data$Ventas, start = c(1, 1), frequency = 4)
```

```
# Gráfica de la serie
```

```
plot(ventas_ts, main = "Serie de tiempo de ventas", xlab = "Trimestres", ylab = "Ventas (miles)",  
     type = "o", pch = 19, lwd = 2, col = "red")
```

Serie de tiempo de ventas





Gráfico de correlación

```
acf(ventas_ts, main = "Gráfico de Autocorrelación (ACF)", col = "orange")
```


Gráfico de Autocorrelación (ACF)



```
# Descomposición aditiva
```

```
ventas_decomp_add <- decompose(ventas_ts, type = "additive")  
plot(ventas_decomp_add, col = "darkgreen")
```


Decomposition of additive time series



Descomposición multiplicativa

```
ventas_decomp_mult <- decompose(ventas_ts, type = "multiplicative")  
plot(ventas_decomp_mult, col = "blue")
```

Decomposition of multiplicative time series



De acuerdo a la gráfica, se puede ver que esta serie es no estacionaria con tendencia creciente y media dependiente del tiempo, lo que nos dice que los valores aumentan constantemente a lo largo del tiempo. Además, en la gráfica de autocorrelación muestra picos importantes en el principio de la gráfica. Esto indica que la serie no cumple con la condición de estacionariedad, ya que sus estadísticas no son constantes en el tiempo y están influenciadas por patrones estacionales y tendencias.

```
resumen_ventas <- ventas_data %>%
  group_by(Año) %>%
  summarise(
    Media = mean(Ventas),
    DesviacionEstandar = sd(Ventas))

print(resumen_ventas)
```

```
## # A tibble: 4 × 3
##   Año Media DesviacionEstandar
##   <dbl> <dbl>          <dbl>
## 1     1  5.35           1.10
## 2     2  6.3            0.987
## 3     3  6.72           1.09
## 4     4  7.15           1.23
```

Ahora, de acuerdo a esta definición de la Universidad de Barcelona, “si a medida que aumenta (o disminuye) el valor medio la desviación típica aumenta (o disminuye) el esquema de agregación adecuado es el multiplicativo; si las desviaciones típicas se mantienen aproximadamente iguales sea cual sea el valor de la media, el modelo adecuado es el aditivo”. Observando los cálculos anteriores, se puede decir que los valores de la desviación estándar indican que no existe un incremento proporcional a la media de cada año. Las desviaciones estándar son relativamente estables y no aumentan consistentemente con el valor medio. Es por esto que el modelo es aditivo.

2. Calcula los índices estacionales y grafica la serie desestacionalizada

```
indices_estacionales <- ventas_decomp_add$seasonal  
  
print("Índices Estacionales:")
```


```
## [1] "Índices Estacionales:"
```

```
print(indices_estacionales)
```

```
##           Qtr1           Qtr2           Qtr3           Qtr4  
## 1 -0.4395833 -1.0687500  0.5895833  0.9187500  
## 2 -0.4395833 -1.0687500  0.5895833  0.9187500  
## 3 -0.4395833 -1.0687500  0.5895833  0.9187500  
## 4 -0.4395833 -1.0687500  0.5895833  0.9187500
```

```
ventas_desestacionalizadas <- ventas_ts - indices_estacionales  
  
plot(ventas_ts, main = "Serie original vs. desestacionalizada", xlab = "Tiempo", ylab = "Ventas  
(miles)", col = "red", lty = 2)  
lines(ventas_desestacionalizadas, col = "blue", type = "o", pch = 19)  
legend("topright", legend = c("Original", "Desestacionalizada"), col = c("red", "blue"), lty =  
1)
```

Serie original vs. desestacionalizada



3. Analiza el modelo lineal de la tendencia

- Realiza la regresión lineal de la tendencia (ventas desestacionalizadas vs tiempo)
- Analiza la significancia del modelo lineal, global e individual
- Haz el análisis de residuos

```
# Regresión Lineal
```

```
modelo_lineal <- lm(ventas_desestacionalizadas ~ ventas_data$Tiempo)  
summary(modelo_lineal)
```


```
##
## Call:
## lm(formula = ventas_desestacionalizadas ~ ventas_data$Tiempo)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2992 -0.1486 -0.0037  0.1005  0.3698
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      5.13917    0.10172   50.52 < 2e-16 ***
## ventas_data$Tiempo 0.14613    0.01052   13.89 1.4e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.194 on 14 degrees of freedom
## Multiple R-squared:  0.9324, Adjusted R-squared:  0.9275
## F-statistic: 193 on 1 and 14 DF,  p-value: 1.399e-09
```

```
# Significancia del modelo
```

```
# Análisis de residuos
```


```
residuos <- residuals(modelo_lineal)
plot(residuos, type = "o", pch = 19, col = "red", main = "Residuos del modelo lineal", xlab = "Observaciones", ylab = "Residuos")
abline(h = 0, col = "black", lty = 2)
```


Residuos del modelo lineal



```
acf(residuos, main = "ACF de los residuos")
```

ACF de los residuos



4. Calcula el CME y el EPAM de la predicción de la serie de tiempo

```
# Predicciones de la tendencia lineal

predicciones_lineales <- predict(modelo_lineal)
errores <- ventas_desestacionalizadas - predicciones_lineales

# Calcular CME y EPAM

CME <- mean(errores^2, na.rm = TRUE)
EPAM <- mean(abs(errores / ventas_desestacionalizadas)) * 100

print(paste("CME:", round(CME, 4)))
```

```
## [1] "CME: 0.0329"
```

```
print(paste("EPAM:", round(EPAM, 4), "%"))
```

```
## [1] "EPAM: 2.3413 %"
```

5. Explora un mejor modelo, por ejemplo un modelo cuadrático: $y = \beta_0 + \beta_1 x + \beta_2 x^2$. Para ello transforma la variable ventas (recuerda que la regresión no lineal es una regresión lineal con una transformación).

```
# Modelo cuadrático

tiempo = 1:length(ventas_desestacionalizadas)

tiempo_cuadrado = tiempo^2

modelo_cuadratico = lm(ventas_desestacionalizadas ~ tiempo + tiempo_cuadrado)

predicciones_cuadraticas = predict(modelo_cuadratico)

# CME y EPAM

CME_cuadratico <- mean((ventas_desestacionalizadas - predicciones_cuadraticas)^2)
EPAM_cuadratico <- mean(abs((ventas_desestacionalizadas - predicciones_cuadraticas) / ventas_desestacionalizadas) * 100)

print(paste("CME:", round(CME_cuadratico, 4)))
```

```
## [1] "CME: 0.027"
```

```
print(paste("EPAM:", round(EPAM_cuadratico, 4), "%"))
```

```
## [1] "EPAM: 2.2299 %"
```

6. Concluye sobre el mejor modelo

De acuerdo con los resultados anteriores, podemos concluir que el mejor modelo es el modelo cuadrático, ya que presenta un CME menor, con un valor de 0.027 en comparación con el 0.0329 del modelo lineal. Esto indica que el modelo cuadrático tiene una mayor precisión al predecir los datos, ya que un CME menor significa que las predicciones están, en promedio, más cerca de los valores reales. Además, el rendimiento del modelo cuadrático en cuanto al indicador EPAM (2.2299 %) es ligeramente mejor que el del modelo lineal (2.3413 %).

7. Realiza el pronóstico para el siguiente año y gráficalo junto con los pronósticos previos y los datos originales.

```
n_periodos <- length(ventas_desestacionalizadas)
tiempo_futuro <- (n_periodos + 1):(n_periodos + 4)
tiempo_futuro_cuadrado <- tiempo_futuro^2

datos_futuros <- data.frame(tiempo = tiempo_futuro, tiempo_cuadrado = tiempo_futuro_cuadrado)

pronostico_futuro <- predict(modelo_cuadratico, newdata = datos_futuros)

plot(tiempo, ventas_desestacionalizadas, type = "l", col = "blue", ylim = range(c(ventas_desestacionalizadas, predicciones_cuadraticas, pronostico_futuro)), xlab = "Tiempo", ylab = "Ventas desestacionalizadas", main = "Pronóstico de Ventas Desestacionalizadas")
lines(tiempo, predicciones_cuadraticas, col = "red", lty = 2)

legend("topleft", legend = c("Datos Originales", "Pronóstico Cuadrático"),
      col = c("blue", "red"), lty = c(1, 2, 2), bty = "n")
```

Pronóstico de Ventas Desestacionalizadas

